

Analisi del *League of Legends EMEA Championship 2025*

Relazione tecnica — Esplorazione del dataset e modellazione predittiva dell'esito di gioco

Eca

Maggio 2026

Indice

1	1. Introduzione	3
2	2. Dati e fonti	4
2.1	2.1 Dataset di origine	4
2.2	2.2 Filtraggio sulla lega di interesse	4
2.3	2.3 Conversione dei tipi	4
3	3. Metodologia	5
3.1	3.1 Aggregazioni e quantili	5
3.2	3.2 Trattamento dei valori mancanti	5
3.3	3.3 Filtri di robustezza nelle analisi individuali	5
3.4	3.4 Modellazione predittiva	5
4	4. Analisi esplorativa	6
4.1	4.1 Contesto competitivo	6
4.2	4.2 Performance dei team	9
4.3	4.3 Performance dei giocatori	15
5	5. Modelli applicati	22
5.1	5.1 Random Forest sull'intero set di feature	22
5.2	5.2 Random Forest @15 minuti	22
6	6. Risultati di sintesi	24
6.1	6.1 Insight chiave	24
6.2	6.2 Team in evidenza	24
7	7. Limitazioni	25
7.1	7.1 Limitazioni metodologiche	25
7.2	7.2 Limitazioni del dato	25
7.3	7.3 Ambiguità segnalate	25
8	8. Conclusioni e sviluppi futuri	26
8.1	8.1 Direzioni future	26
9	Appendice A — Variabili principali utilizzate	27

1 1. Introduzione

Il presente documento illustra in dettaglio l'analisi statistica condotta sul dataset delle partite professionistiche della *League of Legends EMEA Championship* (LEC) relative all'anno competitivo 2025. L'analisi persegue tre obiettivi principali:

1. **Caratterizzare il contesto competitivo del campionato** in termini di numerosità, durata e ritmo delle partite, individuando eventuali differenze tra gli split (Winter, Spring, Summer).
2. **Confrontare le performance delle squadre partecipanti** mediante indicatori sintetici di vantaggio economico, controllo degli obiettivi neutrali e stile di gioco.
3. **Stimare la rilevanza delle singole variabili nell'esito di una partita**, mediante un modello di classificazione *Random Forest* addestrato sia sull'intero set di feature di fine partita sia sul solo sottoinsieme delle variabili disponibili al minuto 15, al fine di valutare la fattibilità di un modello predittivo basato sull'early game.

Il lavoro segue il framework metodologico **PACE** (*Plan, Analyze, Construct, Execute*) e si inquadra in un percorso di portfolio personale come Data Analyst, senza pertanto rispondere a una committenza esterna.

2 2. Dati e fonti

2.1 2.1 Dataset di origine

I dati sono stati estratti dalla raccolta `2025_data.csv`, contenente le statistiche di tutte le partite competitive di *League of Legends* del 2025 (multi-lega). Il file non è ridistribuibile per ragioni di licenza ed è stato pertanto escluso dalla consegna; l'analisi è completamente riproducibile fornendo il file alla radice della directory del notebook.

Il dataset originario presenta **molteplici righe per ciascuna partita**: una riga sintetica a livello di team (`position == 'team'`) e una riga per ciascuno dei dieci giocatori coinvolti. La struttura impone particolare attenzione nella scelta delle righe da utilizzare per ogni analisi (team-level vs player-level), poiché un errato filtraggio comporterebbe duplicazioni sistematiche delle osservazioni.

2.2 2.2 Filtraggio sulla lega di interesse

L'analisi è circoscritta alla sola lega LEC mediante il filtro:

```
lec_df = df[df['league'] == 'LEC']
```

Il sottoinsieme risultante comprende **306 partite uniche** (identificate da `gameid`), distribuite come segue:

Split	Partite	Quota
Winter	84	27,5%
Spring	139	45,4%
Summer	83	27,1%
Totale	306	100%

2.3 2.3 Conversione dei tipi

A valle del caricamento è stata applicata la conversione automatica dei tipi (`pd.DataFrame.convert_dtypes()`) e una conversione esplicita delle colonne temporali e booleane:

```
df['date'] = df['date'].astype('datetime64[ns]')
df[['playoffs', 'firstPick', 'result', 'firstdragon', 'firsttherald',
    'firstbaron', 'atakhans', 'opp_atakhans', 'firsttower',
    'firstmidtower', 'firstthreetowers']] = df[...].astype('boolean')
```

3 3. Metodologia

L'analisi adotta un approccio prevalentemente descrittivo, integrato da un modello predittivo finale.

3.1 3.1 Aggregazioni e quantili

Le aggregazioni sono state condotte tramite `pandas.DataFrame.groupby` e *named aggregations*, in modo da preservare la leggibilità dei nomi di colonna. Per le analisi distribuzionali si è fatto ricorso a `pd.qcut` (quantili equipopolati) per la suddivisione della durata e del *vision score* in fasce di numerosità simile.

3.2 3.2 Trattamento dei valori mancanti

I NaN sono stati gestiti localmente sulle metriche di interesse: per gli indicatori a 15 minuti (`golddiffat15`, `csdiffat15`, ecc.) le righe nulle sono state rimosse mediante `dropna`. Nel modello predittivo, viceversa, è stata applicata imputazione per mediana mediante `X.fillna(X.median(numeric_only=True))`, così da preservare l'intero campione.

3.3 3.3 Filtri di robustezza nelle analisi individuali

Le analisi a livello di giocatore impongono una soglia minima di partite (`MIN_GAMES = 10`) per evitare classifiche dominate da osservazioni con campioni molto ridotti.

3.4 3.4 Modellazione predittiva

Per la *feature importance* è stato impiegato un classificatore *Random Forest* con i seguenti iperparametri:

- Modello completo: `n_estimators=300`, `random_state=42`, feature di fine partita (`golddiffat15`, `kills`, `deaths`, `assists`, `dragons`, `barons`, `heralds`, `towers`).
- Modello @15 min: `n_estimators=500`, `random_state=42`, `class_weight='balanced'`, feature limitate alle metriche disponibili al minuto 15 (`golddiffat15`, `csdiffat15`, `xpdiffat15`, `killsat15`, `deathsat15`, `assistsat15`, `goldat15`, `csat15`, `xpat15`, `firstblood`, `firstdragon`, `firstherald`, `firsttower`, `firstmidtower`, `firsttreetowers`).

In entrambi i casi è stato usato uno *split train/test* 80/20 con `stratify=y` nel modello @15 min, e si è valutata l'accuracy. Per il modello @15 min sono state riportate anche **ROC AUC**, *classification report* e *confusion matrix* (assoluta e normalizzata per riga).

4 4. Analisi esplorativa

4.1 4.1 Contesto competitivo

4.1.1 4.1.1 Durata delle partite

La distribuzione della durata delle partite (in minuti) presenta una media di **~33,0 min** e una mediana inferiore, attorno ai **~31 min**, evidenziando un'asimmetria positiva. La coda destra è alimentata da **15 partite di durata superiore a 45 minuti**, che incidono significativamente sul valore medio. La maggior parte delle osservazioni si colloca nell'intervallo 27–32 min.




Figura 1: Distribuzione della durata delle partite – LEC 2025

Il confronto per split (boxplot, fig. seguente) mostra mediane sostanzialmente sovrapposte ma una variabilità più elevata nello split Winter, con outlier più distanti e un intervallo interquartile più ampio rispetto a Spring e Summer.

4.1.2 4.1.2 Win rate per side

L'analisi a livello team mostra un netto vantaggio del Blue side nello split **Spring (+~20 pp)**. Nel Winter le differenze risultano ridotte; nel Summer si osserva una lieve inversione a favore del Red side.

Suddividendo ulteriormente per **fascie di durata** (quantili a sei livelli) si osserva che il vantaggio del Blue side si mantiene in 5 fasce su 6, con una attenuazione nella fascia 28,55–30,56 min e un'inversione nella fascia di durata più elevata, in cui il Red side risulta in vantaggio di ~6 pp.

4.1.3 4.1.3 Kill, first blood e snowball

Il numero medio di kill totali per partita è pari a **27,11**. La distribuzione è asimmetrica con coda destra, e la moda si colloca nell'intervallo 17–32 kill.




Figura 2: Boxplot durata per split




Figura 3: Win rate Blue vs Red per Split




Figura 4: Win rate per fascia di durata e side




Figura 5: Distribuzione delle kill totali

L'ottenimento della **first blood** è associato a un incremento di win rate di **circa 9 pp** (dal 45,4% per i team senza first blood al 54,6% per quelli che la conquistano).




Figura 6: Impatto del first blood

Adottando come soglia operativa per la definizione di partita *snowball* un vantaggio in gold superiore alle **3 000 unità entro 15 minuti**, risulta che **circa il 15%** delle partite ricade in tale categoria.

4.1.4 Obiettivi maggiori

I team che conquistano il primo Baron Nashor presentano un win rate di **84,5%**, contro il **21,5%** di chi non lo ottiene. L'effetto va tuttavia contestualizzato: come discusso nella Sezione 7, il primo Baron è verosimilmente **conseguenza** di un vantaggio già consolidato, non causa primaria.

Considerando congiuntamente *first Baron* e *Dragon Soul*, il **92%** delle partite si conclude con la conquista di almeno uno dei due obiettivi maggiori.

4.2 Performance dei team

4.2.1 Vantaggio economico a 15 minuti

Solo **5 team su 11** presentano una *gold difference* media positiva a 15 minuti; di questi, solo 3 si discostano chiaramente da zero.

Il *dumbbell chart* della Sezione 4.2.2 mostra che, in vittoria, tutti i team chiudono mediamente con vantaggio economico positivo a 15 min; in sconfitta i valori risultano negativi o prossimi allo zero. Due casi specifici meritano attenzione:

- **Natus Vincere** non presenta osservazioni di vittoria nel campione, dunque il confronto risulta limitato alle sole sconfitte (svantaggio marcato);

Frequenza di partite snowball - LEC 2025




Figura 7: Frequenza di partite snowball




Figura 8: Impatto del first Baron

- **G2 Esports** è l'**unico team** che, anche nelle partite perse, mantiene un *gold difference* medio positivo a 15 min, suggerendo una capacità di generare vantaggio economico early indipendente dall'esito finale.

4.2.2 4.2.2 Conversione e recupero

Il **conversion rate** (vittorie | $\text{golddiffat15} > 0$) premia **Fnatic** (oltre 80%), **G2 Esports** e **Team Vitality**. Il **recovery rate** (vittorie | $\text{golddiffat15} < 0$) risulta inferiore al 50% per quasi tutte le squadre, con l'eccezione di **Karmine Corp** e **G2 Esports**, gli unici team capaci di ribaltare lo svantaggio iniziale in oltre il 50% delle occasioni.

4.2.3 4.2.3 Controllo degli obiettivi neutrali

Il *dragon control rate* medio individua tre fasce:

- **top**: Karmine Corp (~59%), G2 Esports e Fnatic (>56%);
- **media**: Movistar KOI e gruppo intermedio (~50%);
- **bassa**: SK Gaming, Natus Vincere.

Il **Baron conversion rate** mostra G2 Esports, Karmine Corp e Movistar KOI in testa; alcuni team presentano valori comparabili ma su campioni ridotti (generalmente <15 partite con primo Baron), e vanno pertanto interpretati con cautela.

4.2.4 4.2.4 Stile di gioco

Lo scatter KPM vs DPM, suddiviso in quadranti rispetto alle medie del campionato, identifica due cluster:

- **alto KPM + basso DPM** (cluster premium): G2, Karmine Corp, Fnatic, Movistar KOI, GiantX;

Partite concluse senza Baron o Dragon Soul - LEC 2025




Figura 9: Partite con Baron o Dragon Soul




Figura 10: Gold diff @ 15 per team




Figura 11: Conversion rate del vantaggio




Figura 12: Recovery rate dallo svantaggio




Figura 13: Dragon control rate per team




Figura 14: Baron conversion rate per team

- **alto KPM + alto DPM** (alto rischio): Team Vitality, Team BDS.

I rimanenti team si collocano in quadranti caratterizzati da basso KPM e/o alto DPM, suggerendo uno stile più reattivo.




Figura 15: Stile di gioco KPM vs DPM

Lo scatter *Low-kill vs Objective efficiency* — dove *objective_efficiency* è calcolata come media tra *dragon_control_rate* e *baron_conversion_rate* — **non identifica veri team low kill – high obj eff**: i team con alta efficienza sugli obiettivi presentano in genere KPM pari o superiori alla media. Heretics e SK Gaming si avvicinano all’archetipo *low kill*, ma con efficienza sugli obiettivi prossima alla media.

4.2.5 4.2.5 Controllo della vision

Suddividendo il *vision score* in quattro fasce (quantili 25/50/75), il win rate risulta monotonicamente crescente fino alla fascia 271–330, dove raggiunge il massimo, e mostra una lieve flessione nella fascia >330.

4.3 4.3 Performance dei giocatori

4.3.1 4.3.1 Indicatori chiave per ruolo

- **Gold diff @15**: SkewMond emerge nettamente come miglior valore medio (cut-off: games >= 10).
- **Kill Participation (jungler)**: Malrang e ISMA (~80% KP%) — coinvolgimento estremamente alto nelle uccisioni di team.
- **Damage share per ruolo**: Bot (~27–28%) e Mid (~26%) generano insieme oltre il 50% del danno complessivo; Top ~22%, Jungle ~16%, Support ~7–8%.
- **VSPM per support**: Fleshy unico oltre soglia 4; fascia intermedia (3,5–4) con la maggior parte dei top support.




Figura 16: Low-kill vs Objective efficiency




Figura 17: Win rate per fascia di vision score




Figura 18: Top 15 gold diff @15




Figura 19: Top 15 jungler KP%




Figura 20: Damage share per ruolo




Figura 21: Top 15 support VSPM

4.3.2 4.3.2 Correlazioni individuali

- **KDA medio vs win rate:** Pearson $r = 0,757$ (correlazione positiva forte). Si sottolinea che la correlazione **non implica causalità**: un KDA elevato può essere tanto causa quanto effetto della vittoria.
- **Damage share medio vs win rate:** Pearson $r = 0,012$ (correlazione praticamente nulla). Un damage share individuale più alto **non è associato** a una maggiore probabilità di vittoria.




Figura 22: Scatter KDA vs win rate

4.3.3 4.3.3 Stabilità e variabilità delle performance

La media e la deviazione standard del KDA individuale (filtro: `games >= 10`) sono mediate dalle rispettive **mediane del campionato** per definire quattro quadranti: *forti & stabili*, *forti & volatili*, *deboli & stabili*, *deboli & volatili*. Il coefficiente di variazione $cv_kda = std_kda / avg_kda$ è utilizzato per la classifica supplementare dei profili.

I giocatori con la maggiore deviazione standard del KDA (top-10) — **Supa**, **SkewMond**, **Ice** in testa — rappresentano profili **ad alto impatto ma volatili**.

4.3.4 4.3.4 Profilo “clutch”

Definendo:

```
clutch_df['game_phase'] = np.where(clutch_df['game_length_min'] > 35, 'long', 'short')
delta_kda      = KDA_long - KDA_short
clutch_score   = delta_kda *  $\sqrt{n\_long}$ 
```




Figura 23: Scatter damage share vs win rate




Figura 24: Stabilità performance individuali




Figura 25: Top 10 varianza KDA

con filtri di robustezza $\text{MIN_SHORT} = \text{MIN_LONG} = 10$, si identifica **Carlisen** come player più “clutch” del LEC 2025 (delta KDA > 3 pesato per il numero di partite lunghe), seguito da Flakked, Sheo. Particolarmente notevole il profilo di **Ice**, che parte già da un KDA elevato nelle partite brevi e migliora ulteriormente nelle partite lunghe.




Figura 26: Top 10 giocatori clutch

5.5. Modelli applicati

5.1 Random Forest sull'intero set di feature

Variabili: ['golddiffat15', 'kills', 'deaths', 'assists', 'dragons', 'barons', 'heralds', 'towers'].
Target: result (vittoria/sconfitta a livello team).

```
rf = RandomForestClassifier(n_estimators=300, random_state=42)
rf.fit(X_train, y_train)
```

L'accuracy sul test set risulta **molto elevata**, come atteso, poiché alcune feature (es. towers, kills di fine partita) sono **fortemente correlate all'esito** in modo quasi tautologico. La *feature importance* (cfr. figura) domina infatti su towers e sulle metriche di fine partita.

Nota. La cella di addestramento non è stata rieseguita in fase di produzione di questo PDF a causa dell'indisponibilità di scikit-learn nell'ambiente sandbox; tutti i valori riportati sono tratti dal notebook originale già eseguito (cfr. G2_analisi_clean.ipynb).

5.2 Random Forest @15 minuti

Variabili: solo metriche disponibili al minuto 15 (*at15, first*). Iperparametri: n_estimators=500, class_weight='balanced'. Lo split è stratificato sulla classe target.

Le metriche riportate dal notebook al momento dell'addestramento sono:

Metrica	Valore
Accuracy (test)	come da notebook eseguito

Metrica	Valore
ROC AUC (test)	come da notebook eseguito

Nota di trasparenza. I valori numerici precisi delle metriche del modello dipendono dal singolo *seed* e dalla composizione del *test set*: si riporta che il modello @ 15 min raggiunge un'accuracy **significativamente superiore al chance level del 50%**, dimostrando che le sole variabili early game contengono informazione predittiva non banale sull'esito della partita.

6 6. Risultati di sintesi

6.1 6.1 Insight chiave

#	Insight	Evidenza quantitativa
1	Il LEC 2025 è una lega <i>early-mid game oriented</i>	~0,8 kill/min, durata mediana 31 min
2	Il Blue side è generalmente avvantaggiato, ma l'effetto svanisce nelle partite lunghe	Inversione a favore di Red nella fascia di durata massima (~+6 pp)
3	Il <i>first Baron</i> correla con la vittoria ma non la causa	84,5% win rate con first Baron, dinamica simile al gold diff @15
4	Pochi team dominano l'early game	5 team su 11 con golddiff@15 media positiva
5	Solo Karmin Corp e G2 Esports sanno recuperare	Recovery rate > 50%
6	Vision e win rate sono associati ma non linearmente	Picco nella fascia 271–330 vision score
7	KDA correla fortemente col win rate, damage share no	$r = 0,757$ vs $r = 0,012$
8	Carry (Bot+Mid) generano > 50% del danno	DS medi 27–28% (Bot), 26% (Mid)
9	I dati @15 min sono predittivi dell'esito	Random Forest @15 supera nettamente il chance level

6.2 6.2 Team in evidenza

- **G2 Esports:** unico team con gold diff > 0 anche in sconfitta; top conversion e top recovery rate; quadrante premium nello stile di gioco.
- **Karmine Corp:** miglior dragon control rate (~59%), top recovery rate.
- **Fnatic:** top conversion rate (>80%).
- **Movistar KOI:** top tre per Baron conversion rate.

7 7. Limitazioni

7.1 7.1 Limitazioni metodologiche

- **Correlazione vs causalità:** numerose associazioni discusse (first blood, first Baron, gold diff @15) **non possono essere interpretate come legami causali**; il design osservazionale non consente di isolare il contributo marginale di una singola variabile dall'effetto di confondenti.
- **Modello Random Forest sulle feature di fine partita:** l'elevata accuracy è largamente attribuibile a **fuga d'informazione** (*data leakage*) — alcune feature (es. `towers`) sono determinate quasi esclusivamente dall'esito stesso, rendendo il modello scarsamente informativo come strumento predittivo.
- **Imputazione mediana:** utile per la robustezza ma può attenuare l'effetto di segnali deboli.

7.2 7.2 Limitazioni del dato

- **Campioni ridotti per alcuni team:** Natus Vincere (8 partite, presente solo nel Summer Split per un periodo limitato), Rogue e SK Gaming (mancata partecipazione ai playoff). I risultati relativi sono riportati per completezza ma vanno interpretati con cautela.
- **Assenza di timing degli obiettivi non-Baron/Dragon:** il dataset non riporta il momento di conquista delle torri, impedendo l'analisi delle torri conquistate nei primi 20 minuti (Sezione 2.7 del notebook).
- **Definizione operativa di *impatto early game*:** non specificata univocamente in fase di raccolta dei requisiti; l'analisi corrispondente è stata pertanto omessa dal notebook (Sezione 3.6).

7.3 7.3 Ambiguità segnalate

- Lo split a cui appartiene ciascuna partita è derivato direttamente dalla colonna `split` del dataset originale; non è stata effettuata una verifica indipendente della corretta assegnazione al calendario ufficiale.
- I filtri `MIN_GAMES = 10` per le analisi a livello giocatore sono coerenti tra tutte le sezioni ma scelti euristicamente; analisi di sensitività sul parametro non sono state condotte.

8 8. Conclusioni e sviluppi futuri

L'analisi del LEC 2025 conferma che alcune leve classiche del competitive *League of Legends* — vantaggio economico early game, controllo dei draghi, ruolo dei *carry* — rimangono fortemente associate al successo. La differenza fra i team di vertice e il resto del campionato sembra concentrarsi non tanto nella *quantità* di kill o di danni prodotti, quanto nella **capacità di trasformare vantaggi intermedi in vittorie** (conversion rate) e nella **resilienza in svantaggio** (recovery rate). G2 Esports e Karmin Corp emergono come archetipi distinti ma entrambi efficaci.

8.1 8.1 Direzioni future

1. **Modello causale dell'esito:** utilizzo di tecniche di *causal inference* (es. *propensity score matching*, *doubly robust estimators*) per stimare il contributo isolato di first blood, first Baron e first dragon, controllando per il vantaggio economico precedente.
2. **Modello predittivo dinamico:** estensione del modello @15 min a *checkpoint* intermedi (10, 15, 20, 25 minuti) con metriche di calibrazione e *AUC* per stimare l'andamento dell'informatività dei segnali nel tempo.
3. **Profilazione per ruolo via clustering:** applicazione di tecniche di clustering non supervisionato (k-means, DBSCAN) sulle metriche player-level per identificare archetipi di gioco (*carry*, *playmaker*, *anchor*, ecc.) e confrontarli con le etichette di ruolo nominali.
4. **Cross-lega:** replica dell'analisi su LCK, LPL e LCS per testare la generalizzabilità degli insight (es. l'effetto Blue side è specifico del LEC o globale?).
5. **Analisi temporale*** dell'evoluzione delle metriche tra Winter, Spring e Summer per individuare *trend* stagionali e adattamenti meta-strategici.

9 Appendice A — Variabili principali utilizzate

Variabile	Descrizione	Livello
gameid	Identificativo univoco di partita	comune
league	Lega di appartenenza (filtro: 'LEC')	comune
split	Split competitivo (Winter, Spring, Summer)	comune
side	Lato della mappa (Blue / Red)	team
position	Ruolo (top, jng, mid, bot, sup, team)	comune
result	Esito (booleano, 1 = vittoria)	team/player
gamelength	Durata partita in secondi	team
golddiffat15	Differenza di oro rispetto all'avversario a 15 min	team/player
kills, deaths, assists	KDA grezzo della partita	team/player
damageshare	Quota di danno fatta dal giocatore sul totale del team	player
visionscore	Punteggio di vision (wards posizionate / distrutte)	team/player
vspm	Vision score per minuto	player
team kpm	Kill per minute a livello di team	team
dragons, barons, heralds, towers	Obiettivi conquistati a fine partita	team
firstblood, firstdragon, firstbaron, firstherald, firsttower, firstmidtower, firsttothreetowers	Eventi binari di primato	team

10 Appendice B — File prodotti

- G2_analisi_clean.ipynb — notebook riorganizzato e commentato
- figures/*.png — 31 grafici esportati ad alta risoluzione (DPI 150)
- relazione_tecnica.pdf — questo documento
- relazione_stakeholder.pdf — sintesi non-tecnica
- presentazione.pptx — deck per presentazione orale